SUJET

7ARF : TRANSLITTÉRATION DE L'ARABIZI TUNISIEN VERS L'ÉCRITURE ARABE

À l'aide d'un Encodeur–Décodeur LSTM avec attention de Bahdanau

Cours : NLP

Master AIDA | Novembre 2026

Réalisé par : Bak Ali Aref

Encadré par : Pr. Tarifa Amal

Année universitaire : 2026 – 2027

حرف 7arf : lire l'Arabizi tunisien en arabe

Rapport technique · Génération de texte avec un Encodeur–Décodeur LSTM écrit from scratch (PyTorch)

1 INTRODUCTION

J'écris souvent à ma mère en **Arabizi tunisien**, comme beaucoup de Tunisiens. Maman comprend le français et l'arabe, mais pas l'Arabizi : ce sont surtout **les chiffres** qui la perdent (un 3 ou un 7 reste pour elle un nombre, pas une lettre). **7arf** convertit automatiquement mes messages en écriture arabe.

MESSAGE ENVOYÉ	CE QUE MAMAN LIT
`3andi 5ouya w o5ti`	عندي خويا و اختي
`ena n7eb tounes`	انا نحبّ تونس

Difficultés. Les chiffres remplacent des lettres : le 3 note ع et le 7 note ح. L'orthographe est libre, le français se mêle à l'arabe, et les données annotées sont rares.

Formulation. Tâche séquence → séquence au niveau du caractère : le modèle génère une lettre arabe à la fois, en tenant compte de l'entrée x et des lettres déjà écrites :

$$P(y \mid x) = \prod_{t=1}^{T} P(y_t \mid y_1, \ldots, y_{t-1}, x)$$

2 NOTIONS UTILISÉES

Embeddings ; LSTM avec *hidden state* et *cell state* ; Encodeur–Décodeur avec tokens `<SOS>`/`<EOS>` ; attention de Bahdanau ; lecture bidirectionnelle (BiLSTM).

3 DONNÉES

TArC (Gugliotta & Dinarelli, LREC 2020, CC BY-NC-SA 4.0) : Arabizi tunisien de réseaux sociaux, forums, blogs et rap, annoté mot par mot. On garde l'Arabizi (entrée), sa forme arabe CODA (cible) et les mots étrangers (recopiés).

	TRAIN	VALID.	TEST
Phrases (4 504)	3 605	451	448
Fenêtres de 6 mots	6 864	918	862

Découpage 80/10/10 par phrase, doublons dans la même partie : aucune fuite vers le test.

4 PRÉTRAITEMENT

- **Normalisation** : Unicode, minuscules, pseudonymes → §, `aaaaa` → `aaa`.
- **Tokenisation en caractères** : en mots, 25 % des mots du test seraient inconnus ; en caractères, 0,1 %.
- **Vocabulaires** (train seul) : 86 symboles source, 122 cible, plus `<PAD>` `<UNK>` `<SOS>` `<EOS>`.
- **Padding** par batch ; aucune séquence ne dépasse 120 caractères.

5 ARCHITECTURE

Encodeur : embedding (64) → LSTM (256). Il lit l'Arabizi et produit un état h_i par caractère.

Décodeur : embedding → LSTM (512) → Linear → softmax sur 122 lettres. Il écrit l'arabe lettre par lettre, de `<SOS>` jusqu'à `<EOS>`.

Attention de Bahdanau : sans elle, toute la phrase doit tenir dans un seul vecteur. À chaque pas t, le décodeur (état s_{t-1}) donne un score à chaque état h_i de l'encodeur, le transforme en poids α par softmax, puis en fait un contexte c_t : pour écrire ع, il regarde le 3.

$$e_{t,i} = v^{\top} \tanh(W_h\, h_i + W_s\, s_{t-1})$$

$$\alpha_{t,i} = \frac{\exp(e_{t,i})}{\sum_j \exp(e_{t,j})} \qquad c_t = \sum_i \alpha_{t,i}\, h_i$$

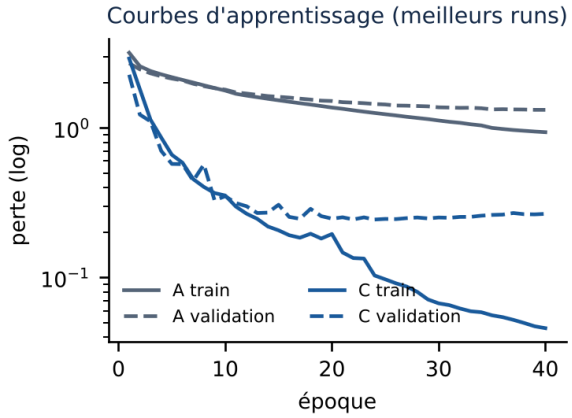
MODÈLE	MODIFICATION TESTÉE	PARAM.
A	LSTM sans attention (baseline)	1,85 M
B	+ attention de Bahdanau	2,61 M
C	+ encodeur BiLSTM (lit dans les deux sens)	3,83 M
D	C sur mots isolés, sans contexte	3,83 M
E	C + teacher forcing de 1 à 0,5	3,83 M

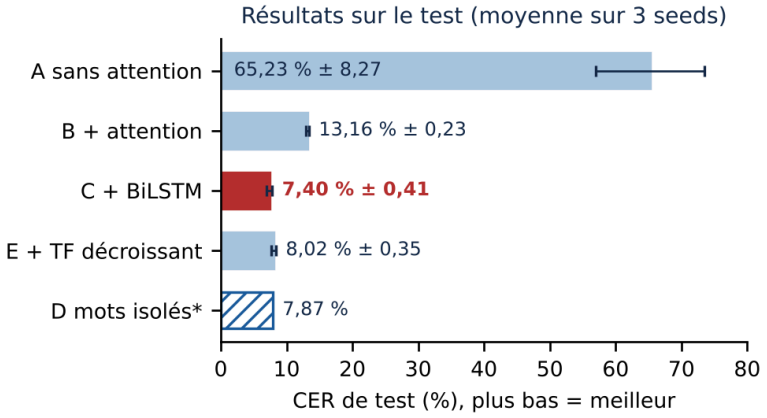
Param. = nombre de paramètres du modèle, c'est-à-dire de poids appris pendant l'entraînement. 1,85 M signifie 1,85 million de nombres ajustés. L'attention puis le BiLSTM ajoutent des poids, d'où des modèles plus grands. Une seule modification à la fois : chaque écart a une cause identifiable.

6 ENTRAÎNEMENT

- **Perte** : entropie croisée par caractère. **Optimiseur** : Adam (lr 0,001), batch 64, dropout 0,3.
- **Procédure** : 40 époques au maximum ; on garde le meilleur CER de validation (`best.pt`) et on arrête après 5 époques sans gain.
- **Seed** : elle fixe le hasard (poids initiaux, ordre des batchs, dropout). Elle rend l'expérience **reproductible**. Chaque modèle est entraîné avec **3 seeds** pour vérifier qu'un gain n'est pas dû à une initialisation chanceuse. Le modèle A varie de 60 % à 75 % de CER selon la seed, alors que C reste stable.
- 13 entraînements sur GPU T4 (Google Colab), environ 2 h au total.

7 RÉSULTATS EXPÉRIMENTAUX





Courbes. A sous-apprend : sa perte reste haute. C apprend vite ; sa perte de validation remonte un peu après l'époque 24 (léger surapprentissage), mais l'early stopping sur le CER le contrôle.

CER (taux d'erreur par caractère, plus bas = meilleur) sur le test, une seule fois. *D est mesuré sur des mots isolés : non comparable directement.

MODÈLE	CER %	EXACT %	BLEU
A	65,23	15,66	6,39
B	13,16	42,69	55,83
C (meilleur)	**7,40**	**54,45**	**67,43**
E	8,02	51,24	65,92

8 EXEMPLES GÉNÉRÉS

ENTRÉE	SORTIE DU MODÈLE C
`9adech soum hedha` ✓	قدّاش سوم هاذا
`el 7ya` × (voyelle longue)	ال حية
`we_dream` × (devait être recopié)	والدرام

Causes des erreurs : lettres stylisées inconnues (`βēšt`), voyelles longues, lettres ambiguës (`th`), mots étrangers. Beaucoup sont des variantes d'orthographe qu'un lecteur comprend quand même.

Beam search : au lieu de prendre à chaque pas la lettre la plus probable (greedy), on garde **les 5 meilleures hypothèses** et on choisit le mot le plus probable **dans son ensemble**. Une erreur du début peut ainsi être évitée. Sur 100 exemples, le CER passe de 11,52 % à 10,28 %, mais c'est plus lent : le greedy reste le mode par défaut.

+ BONUS



Application web : on écrit en Arabizi sur l'iPhone, l'arabe s'affiche sur le Nokia 3310. **OCR** (à droite, onglet Capture) : Tesseract lit le texte d'une capture d'écran avant la translittération.

9 DISCUSSION

- **L'attention est décisive** : −52 points de CER entre A et B.
- **Le BiLSTM aide** (−5,76 points), avec aussi 46 % de paramètres en plus.
- **Le teacher forcing décroissant n'apporte rien** ici (+0,61 point, de l'ordre de la variabilité).
- **Points forts** : pipeline complet from scratch, comparaison contrôlée, attention interprétable (le modèle retrouve seul que le 3 donne ع).
- **Limites** : petit corpus surtout tunisois, une seule référence, contexte de 6 mots.
- **Améliorations** : plus de données, copie des mots français, Transformer.

10 CONCLUSION

Le meilleur modèle, **C (BiLSTM + attention)**, atteint **7,40 ± 0,41 %** de CER sur le test : plus de 92 % des lettres sont correctes, et mes messages deviennent en grande partie lisibles en arabe pour maman. Ce projet nous a appris à passer du texte aux nombres, à comprendre l'intérêt de l'attention et à mener des expériences rigoureuses (seeds, validation, test unique).

Données : E. Gugliotta & M. Dinarelli, « TArC », LREC 2020 · D. Bahdanau et al., ICLR 2015